R PROGRAMMING







ผู้ช่วยศาสตราจารย์ ดร. อัชฌาณัท รัตนเลิศนุสรณ์

สาขาสถิติประยุกต์ คณะวิทยาศาสตร์และเทคโนโลยี มหาวิทยาลัยเทคโนโลยีราชมงคลธัญบุรี



สารบัญ

Contents

- 📍 วัตถุพื้นฐานในโปรแกรม R
- าการอ่านข้อมูลจากแฟ้มชนิด text
- าการอ่านข้อมูลจากแฟ้มชนิด csv
- าารบันทึกข้อมูลเป็นแฟ้มชนิด text
- าารบันทึกข้อมูลเป็นแฟ้มชนิด csv
- าารคำนวณค่าสถิติเบื้องต้น
- าารจัดการค่าสูญหาย (missing values)
- าารตรวจสอบค่าผิดปกติ (outliers)

R data objects พื้นฐานมีดังนี้

- vectors
- lists
- matrices
- arrays
- factors
- data frames

vectors มีลักษณะการเก็บข้อมูลเป็นแถวหนึ่งแถว หรือเป็นคอลัมน์หนึ่ง คอลัมน์ สามารถเก็บข้อมูลชนิดเดียวกันเท่านั้น

การสร้าง vectors สามารถใช้ฟังก์ชัน c() --concatenate

```
ตัวอย่างเช่น > v1<-c(20,15,30.5,42.7)
> v1
[1] 20.0 15.0 30.5 42.7
> mode(v1)
[1] "numeric"
> v2<-c("20","15","30.5","42.7")
> v2
[1] "20" "15" "30.5" "42.7"
> mode(v2)
[1] "character"
```

กรณีเก็บข้อมูลต่างชนิดกัน โปรแกรม R จะเปลี่ยนชนิดข้อมูลให้เป็นชนิดเดียวกัน ตัวอย่างเช่น

```
> v3<-c(20, "Somchai", 42L, 4i)
> v3
[1] "20" "Somchai" "42" "0+4i"
```

ตัวแปร v3 (หรือเวกเตอร์ v3) เก็บข้อมูลชนิดตัวอักษรเท่านั้น

การอ้างอิงสมาชิกของเวกเตอร์

```
#######################
# vector01.R #
x < -C()
X
y < -c(2,4,6,8,1,3,5,7)
У
y[2]
y[2:5]
y[-c(3,4,6)]
y[9:10] < -c(9,11)
У
y[y>5]
y[y>=4 \& y<=9]
y[y <=5 | y >=8]
```

ผลลัพธ์ของคำสั่งใน vector01.R

```
> x<-c()
> x
NULL
> y<-c(2,4,6,8,1,3,5,7)
> y
[1] 2 4 6 8 1 3 5 7
> y[2]
[1] 4
> y[2:5]
[1] 4 6 8 1
> y[-c(3,4,6)]
[1] 2 4 1 5 7
> y[9:10]<-c(9,11)
> y
[1] 2 4 6 8 1 3 5 7 9 11
> y[y>5]
[1] 6 8 7 9 11
> y[y>=4 \& y<=9]
[1] 4 6 8 5 7 9
> y[y<=5 | y>=8]
[1] 2 4 8 1 3 5 9 11
```

```
lists เป็นที่เก็บข้อมูลต่างชนิดกัน( เวกเตอร์ ฟังก์ชัน หรือ ลิสต์)<u>ไว้ด้วยกัน</u>
 การสร้าง lists สามารถใช้ฟังก์ชัน list()
 ตัวอย่างการสร้าง list > list1 <- list(c(60,70,90),7.5,sqrt)
                     > list1
                     [1] 60 70 90
                     [1] 7.5
                     [[3]]
                     function (x) .Primitive("sqrt")
```

สมาชิกตัวแรกของลิสต์เป็นเวกเตอร์ สมาชิกตัวที่สองเป็นตัวเลข และสมาชิกตัวที่สาม เป็นฟังก์ชัน sqrt

• การอ้างอิงสมาชิกใน list

■ ผลลัพธ์ของ list01.R

```
> v<-c(4,7,10,9,15,12)
> L1<-list(a=v,b=17.5,c=sqrt)</pre>
$a
[1] 4 7 10 9 15 12
$b
[1] 17.5
$c
function (x) .Primitive("sqrt")
> L1$a
[1] 4 7 10 9 15 12
> L1$b
[1] 17.5
> L1$c
function (x) .Primitive("sqrt")
> L1$a[1:4]
[1] 4 7 10 9
> L1$a[L1$a>9]
[1] 10 15 12
```

matrices เป็นที่เก็บข้อมูลแบบอะเรย์ 2 มิติ ขนาด nxm

ตัวอย่างการสร้างเมทริกซ์ด้วยฟังก์ชัน matrix()

ตัวแปร Matx เป็นเมทริกซ์ขนาด 2x3

• การอ้างอิงสมาชิกใน matrix

■ ผลลัพธ์ของ matrix01.R

```
> v<-c(1,7,9,2,8,10)
> X<-matrix(v,nrow=2,ncol=3)</pre>
> X
 [,1][,2][,3]
[1,] 1 9 8
[2,] 7 2 10
> X[1,]
[1] 1 9 8
> X[1:2,]
 [,1][,2][,3]
[1,] 1 9 8
[2,] 7 2 10
> X[,1]
[1] 1 7
> X[,1:3]
 [,1][,2][,3]
[1,] 1 9
[2,] 7 2
> X[,-2]
 [,1][,2]
[1,] 1 8
[2,] 7 10
> X[X>5]
[1] 7 9 8 10
```

arrays เป็นที่เก็บข้อมูลแบบอะเรย์ 1 มิติ , 2 มิติ และ 3 มิติ

ตัวอย่างการสร้างอะเรย์ด้วยฟังก์ชัน array()

• การอ้างอิงสมาชิกใน array

■ ผลลัพธ์ของ array01.R

```
> v<-c(1,4,7,10,2,5,8,11)
> A<-array(v,dim=c(4,2))
    [,1][,2]
[1,] 1 2
[2,] 4
[3,] 7 8
[4,]
> A[1,]
[1] 1 2
> A[2:3,]
    [,1][,2]
[1,] 4
[2,] 7
> A[,1]
[1] 1 4 7 10
> A[,1:2]
    [,1][,2]
[1,] 1 2
[2,] 4 5
[3,] 7 8
[4,] 10 11
> A[-3,]
    [,1][,2]
[1,] 1 2
[2,]
[3,]
    10 11
> A[A <= 2 | A >= 7]
[1] 1 7 10 2 8 11
```

factors เป็นที่เก็บข้อมูลจำแนกประเภท อาทิ เพศ อาชีพ ระดับการศึกษา เป็นต้น

์ ตัวอย่างการสร้าง Factors ด้วยฟังก์ชัน factor()

```
> gender <- factor(c("Male","Female","Female","Male","Female"))
> gender
[1] Male    Female Female Male    Female
Levels: Female Male
```

ตัวแปร gender เป็นตัวแปรชนิด factors เก็บข้อมูลจำแนกกลุ่ม มี 2 กลุ่ม

คือ เพศหญิง และเพศชาย

• การอ้างอิงสมาชิกใน factor

■ ผลลัพธ์ของ factor01.R

```
> gender<-
c("male","female","male")
> F<-factor(gender)
> F
[1] male female male
Levels: female male
> F[1]
[1] male
Levels: female male
> F[1:2]
[1] male female
Levels: female male
Levels: female male
```

data frames เป็นที่เก็บข้อมูลแบบตาราง(Table) หรือแฟ้มข้อมูล (data file) สามารถตั้งชื่อคอลัมน์หรือฟิลด์(fields)ได้ มีเงื่อนไขว่าจำนวนแถวของทุกคอลัมน์ต้อง เท่ากัน

ตัวอย่างการสร้าง data frames ด้วยฟังก์ชัน data.frame()

การอ้างอิงสมาชิกใน data frames


```
2 # datafr.r
 3 - ########################
 4 name<-c("Wattana", "Somchai", "Arunee")
  gender<-c("Male","Male","Female")</pre>
 6 age <-c(20,19,25)
 7 student.dat<-data.frame(name,gender,age)</pre>
 8 student.dat
 9 student.dat[1,] #display row#1
10 student.dat[,2] #display col#2
11 student.dat[,-2] #display all col,except col#2
12 student.dat[3,2] #display a member row#3,col#2
```

ผลลัพธ์ที่ได้

```
Console
      Terminal ×
> name<-c("Wattana", "Somchai", "Arunee")</pre>
> gender<-c("Male","Male","Female")</pre>
> age < -c(20,19,25)
> student.dat<-data.frame(name,gender,age)</pre>
> student.dat
     name gender age
1 Wattana Male 20
2 Somchai Male 19
3 Arunee Female 25
> student.dat[1,] #display row#1
     name gender age
1 Wattana Male 20
> student.dat[,2] #display col#2
[1] "Male" "Male" "Female"
> student.dat[,-2] #display all col,except col#2
     name age
1 Wattana 20
2 Somchai
          19
3 Arunee 25
> student.dat[3,2] #display a member row#3,col#2
[1] "Female"
```



ก่อนที่จะอ่านข้อมูลให้เตรียมไฟล์ชนิด txt (Text documents) จากโปรแกรม Notepad ดังรูป



ข้อควรระวัง การพิมพ์ข้อมูลชื่อจังหวัดต้องไม่เว้นวรรค และการพิมพ์ตัวเลข ประชากรต้องไม่ใส่เครื่องหมาย , (comma)

ผศ.ดร.อัชฌาณัท รัตนเลิศนุสรณ์

การอ่านข้อมูลจากแฟ้มข้อมูลชนิด text

ข้อควรระวัง ในฟังก์ชัน read.table() เมื่อระบุ header=TRUE แสดงว่า ให้ใช้ข้อมูลแถวแรกในไฟล์ population.txt มาเป็นชื่อคอลัมน์ โดยปกติ ฟังก์ชันนี้จะกำหนดให้ header=FALSE

การอ่านข้อมูลจากแฟ้มข้อมูลชนิด text


```
การอ่านข้อมูลเข้ามาในโปรแกรม Rแล้วควรเก็บไว้ในตัวแปรชนิด data frames
เพื่อความสะดวกในการเรียกใช้งานภายหลังดังนี้
```

>



การอ่านข้อมูลจากแฟ้มข้อมูลชนิด csv

ก่อนที่จะอ่านข้อมูลให้เตรียมไฟล์ชนิด csv (Comma delimited)จาก โปรแกรม Microsoft Excel ดังนี้



การอ่านข้อมูลจากแฟ้มข้อมูลชนิด csv



>

การอ่านข้อมูลจากแฟ้มข้อมูลชนิด csv

การอ่านข้อมูลเข้ามาในโปรแกรม Rแล้วควรเก็บไว้ในตัวแปรชนิด data frames เพื่อความสะดวกในการเรียกใช้งานภายหลังดังนี้

```
> popucsv.dat<-data.frame(read.csv("population.csv",
header = TRUE))</pre>
```

> popucsv.dat

province population

1 Bangkok 8515212

2 Nakhon Pathom 1001077

3 Nonthaburi 1424417

4 Pathum Thani 1399285

5 Samut Prakan 1941323

6 Samut Sakhon 921354

>



การบันทึกข้อมูลลงแฟ้มข้อมูลชนิด text


โปรแกรม R สามารถใช้ตัวแปร data frames เพื่อบันทึกข้อมูลลงแฟ้ม csv และ txt ได้ดังนี้

ตัวอย่างการบันทึกข้อมูลลงแฟ้ม txt ดังนี้

ผศ.ดร.อัชฌาณัท รัตนเลิศนุสรณ์

การบันทึกข้อมูลลงแฟ้มข้อมูลชนิด text

ผลลัพธ์ที่ได้คือแฟ้ม dataabc.txt ซึ่งเก็บอยู่ที่ working directories ของ โปรแกรม R ดังนี้



ผศ.ดร.อัชฌาณัท รัตนเลิศนุสรณ์

การบันทึกข้อมูลลงแฟ้มข้อมูลชนิด text



เมื่อเปิดไฟล์ dataabc.txt จะเห็นข้อมูลดังรูป

การบันทึกข้อมูลลงแฟ้มข้อมูลชนิด csv


```
ตัวอย่างการบันทึกข้อมูลลงแฟ้ม csv ดังนี้
```

```
> number 2 < -1:5
> number2
[1] 1 2 3 4 5
> Month<-month.name[1:5]</pre>
> Month
[1] "January" "February" "March" "April" "May"
> data2<-data.frame(number2,Month)</pre>
> data2
 number2 Month
       1 January
       2 February
       3 March
       4 April
               May
 write.csv(data2, "months.csv", row.names = FALSE)
```

ผศ.ดร.อัชฌาณัท รัตนเลิศนุสรณ์


การบันทึกข้อมูลลงแฟ้มข้อมูลชนิด csv

ผลลัพธ์ที่ได้คือแฟ้ม months.csv ซึ่งเก็บอยู่ที่ working directories ของ โปรแกรม R ดังนี้



การบันทึกข้อมูลลงแฟ้มข้อมูลชนิด csv

• เมื่อเปิดไฟล์ months.csv จะเห็นข้อมูลดังรูป



การคำนวณค่าสถิติเบื้องต้น

ฟังก์ชันทางสถิติที่ใช้คำนวณค่าสถิติเบื้องต้นของข้อมูลมีดังนี้

ฟังก์ชัน	คำอธิบาย
mean()	หาค่าเฉลี่ยเลขคณิตของข้อมูลใน เวกเตอร์
median()	หามัธยฐานของข้อมูลในเวกเตอร์
sum()	หาค่าผลรวมของข้อมูลในเวกเตอร์
length()	หาจำนวนข้อมูลในเวกเตอร์
min()	หาข้อมูลในเวกเตอร์ที่มีค่าน้อยที่สุด
max()	หาข้อมูลในเวกเตอร์ที่มีค่ามากที่สุด

การคำนวณค่าสถิติเบื้องต้น



ตัวอย่างการใช้ฟังก์ชันทางสถิติ

```
> x<-c(1,3,4,7,6,9)
> X
[1] 1 3 4 7 6 9
> mean.x<-mean(x)</pre>
> mean.x
[1] 5
> median.x<-median(x)</pre>
> median.x
[1] 5
> sum.x < -sum(x)
> sum.x
[1] 30
> n<-length(x)</pre>
> n
[1]6
```

ผศ.ดร.อัชฌาณัท รัตนเลิศนุสรณ์

การคำนวณค่าสถิติเบื้องต้น



```
ถ้าต้องการหาค่าฐานนิยมของข้อมูล สามารถหาได้ดังนี้
```

```
> y<-c(3,4,4,4,5,6,8)
> y
[1] 3 4 4 4 5 6 8
> which.max(table(y))
4
2
```

หมายความว่า mode คือ 4 ส่วนตัวเลข 2 เป็นลำดับที่ของ mode หลังจากเรียง ข้อมูลจากน้อยไปมากด้วยฟังก์ชัน table()

ถ้าใช้ฟังก์ชัน mode() จะเป็นการตรวจสอบชนิดของข้อมูล

```
> y<-c(3,4,4,4,5,6,8)
> mode(y)
[1] "numeric"
```



ฟังก์ชันทางสถิติที่ใช้วัดการกระจายของข้อมูลมืดังนี้

ฟังก์ชัน	คำอธิบาย
range()	หาค่าสูงสุดและต่ำสุดของข้อมูลใน เวกเตอร์
diff()	หาผลต่างของข้อมูล
sd()	หาค่าส่วนเบี่ยงเบนมาตรฐานของข้อมูล ตัวอย่าง
var()	หาค่าความแปรปรวนของข้อมูลตัวอย่าง

การวัดการกระจายข้อมูล

ตัวอย่างการใช้ฟังก์ชันวัดการกระจายของข้อมูล

```
> z<-1:10
 [1] 1 2 3 4 5 6 7 8 9 10
> range(z) #หาค่าต่ำสุดและค่าสูงสุดของข้อมูล
[1] \quad 1 \quad 10
> diff(range(z)) #หาค่าพิสัยของข้อมูล
[1]9
                       #หาค่าส่วนเบี่ยงเบนมาตรฐานของข้อมูลตัวอย่าง
> sd(z)
[1] 3.02765
                       #หาความแปรปรวนของข้อมูลตัวอย่าง
> var(z)
[1] 9.166667
```

การจัดการค่าสูญหาย (missing values)



โปรแกรม R ใช้ฟังก์ชัน na.omit() เพื่อลบค่าสูญหายออกไปจากเวกเตอร์ หรือ data frames

```
> x<-c(1,5,7,4,NA)
> X
[1] 1 5 7 4 NA
> x.new<-na.omit(x)</pre>
> x.new
[1] 1 5 7 4
attr(, "na.action")
[1] 5
attr(,"class")
[1] "omit"
```


การตรวจสอบค่าผิดปกติ (outliers)



ค่าผิดปกติในเวกเตอร์ สามารถตรวจสอบได้ดังนี้

ใช้แผนภาพ boxplot ตรวจดูค่าที่กระจายออกจากกลุ่ม

- > x<-c(20,35,40,60,120)
- > boxplot(x)
- >



การตรวจสอบค่าผิดปกติ (outliers)

```
็นอกจากนี้ยังสามารถใช้ R package ชื่อ outliers หาค่าผิดปกติได้
ตัวอย่างการตรวจสอบค่าผิดปกติ
> x<-c(20,35,40,60,120)
[1] 20 35 40 60 120
> library("outliers") #load R package outliers
                   # เรียกใช้ฟังก์ชัน outlier
> outlier(x)
[1] 120
ค่าผิดปกติ คือข้อมูลที่มีค่าเท่ากับ 120
หมายเหตุ: ฟังก์ชัน outlier() ใช้หาระยะห่างที่มากที่สุดระหว่างข้อมูลค่าที่
ต้องการตรวจสอบกับค่าเฉลี่ยเลขคณิตที่ตัดข้อมูลค่านั้นออก
```

การตรวจสอบค่าผิดปกติ (outliers)

หรือเราเขียนคำสั่งขึ้นเองเพื่อตรวจสอบค่าผิดปกติ

```
ตัวอย่างการตรวจสอบค่าผิดปกติ
> x<-c(20,35,40,60,120)
     20 35 40 60 120
> meanx.1 < -mean(c(35,40,60,120))
> meanx.2 < -mean(c(20,40,60,120))
> meanx.3 < -mean(c(20,35,60,120))
> meanx.4 < -mean(c(20,35,40,120))
> meanx.5 < -mean(c(20,35,40,60))
> meanx<-
c(meanx.1,meanx.2,meanx.3,meanx.4,meanx.5)
> distance<-x-meanx</pre>
> cbind(x,meanx,distance)
       x meanx distance
[1,] 20 63.75 -43.75
[2,] 35 60.00 -25.00
    40 58.75 -18.75
      60 53.75 6.25
     120 38.75 81.25
                          ระยะห่างมากที่สุด
```

ค่าผิดปกติ